

Processamento de Dados Distribuídos

Carlos Henrique Brito Malta Leão

Departamento de Ciência da Computação
Universidade Federal de Minas Gerais (UFMG)
chbmleao@ufmg.br

Computação em Nuvem

Professor
Italo Fernando Scota Cunha
italocunha@ufmg.br

1. INTRODUÇÃO

A Computação em Nuvem e o Big Data, embora representem conceitos distintos, frequentemente são abordados em conjunto devido à estreita interação entre eles. Enquanto o Big Data diz respeito à capacidade de lidar com uma grande quantidade de dados usando paradigmas de computação paralelos, a computação em nuvem normalmente refere-se à oferta de recursos escaláveis de processamento e armazenamento, o que também inclui problemas característicos de Big Data. Nesse cenário, a computação em nuvem proporciona a computação e o armazenamento necessários para lidar com grandes quantidades de dados utilizando paradigmas paralelos de forma eficiente e flexível.

Dentro desse contexto, este projeto tem como objetivo explorar e analisar um conjunto de dados utilizando a ferramenta Apache Spark, um dos frameworks mais populares no ecossistema de Big Data. O Spark destaca-se por sua alta performance no processamento distribuído e vem sendo amplamente adotado em sistemas em nuvem devido à sua capacidade de escalabilidade e integração com diferentes fontes de dados.

Especificamente, no contexto do presente trabalho, utilizaremos uma base de dados de músicas de playlists do Spotify, uma das principais plataformas de streaming de música no mundo. O estudo do consumo musical é relevante para diversas áreas do conhecimento, uma vez que padrões de consumo de música estão frequentemente relacionados à linguagem, sentimentos e comportamentos dos usuários, bem como ao ambiente cultural ao qual estão inseridos. Na ciência da computação, por exemplo, compreender esses padrões contribui significativamente para o avanço de sistemas de recomendação, aprimorando sua precisão e personalização.

O código foi desenvolvido em *Python*, utilizando a biblioteca *PySpark* para processamento de dados, além das bibliotecas *Matplotlib* e *Seaborn* para a geração e visualização de gráficos. No entanto, a máquina disponibilizada no servidor do trabalho prático não possuía a biblioteca *Seaborn* instalada. Para contornar essa limitação, foi criada uma máquina virtual dedicada exclusivamente à instalação e uso dessa biblioteca.

2. ESTATÍSTICAS SOBRE DURAÇÃO DE FAIXAS

No Spotify, existem álbuns com faixas de curta duração, como transições entre sons de um álbum ou propagandas. Porém, da mesma forma, existem sons de longa duração, que às vezes se estendem por mais de uma hora, que é o caso de shows completos ou mixagens de músicas. Esses tipos de faixas, são considerados outliers, que devem ser removidos para posteriores análises de dados. Outliers são pontos de dados que estão distantes do valor

médio de um grupo estatístico, considerados exceções.

Na presente tarefa, faremos uma análise estatística da duração das faixas presentes na base de dados. Para calcular a duração mínima, média e máxima, utilizamos algumas funções otimizadas e performáticas da biblioteca *pyspark*. Além disso, também realizamos os cálculos do primeiro e terceiro quartil, além da faixa interquartil, utilizando a função *approxQuantile* também do *pyspark*, com um erro relativo de 0.00001. O parâmetro de erro dessa função é extremamente importante, pois o cálculo 100% preciso dos quartis exige uma grande quantidade de computação. Por esse motivo, permitimos que o algoritmo tenha certa imprecisão, que não apresenta grandes impactos nos resultados obtidos e melhora a utilização dos recursos computacionais disponíveis para a execução.

No nosso contexto, consideramos como outliers as faixas presentes na seguinte interseção. $Q1$ representa o primeiro quartil, $Q3$ o terceiro e IQR a faixa interquartil encontrados.

$$Q1 - 1.5 * IQR < x < Q3 + 1.5 * IQR$$

Os outliers encontrados são removidos, e as estatísticas de duração de faixas são novamente calculadas. As principais mudanças encontradas na remoção dos outliers são na duração mínima (de 0 ms para 1 min e 48 seg) e na duração máxima (quase 3 horas para 5 min e 49 seg).

Mínima duração (ms)	Duração média (ms)	Duração máxima (ms)
0	234408.54976216817	10435467

Tabela 1: Estatísticas de duração de faixas com outliers

Quartil 1 - 25% (ms)	Quartil 3 - 75% (ms)	Faixa interquartil (ms)
198333	258834	60501

Tabela 2: Proporção dos quartis

Mínima duração (ms)	Duração média (ms)	Duração máxima (ms)
107582	226899.35353939075	349583

Tabela 3: Estatísticas de duração de faixas sem outliers

3. ARTISTAS MAIS FAMOSOS AO LONGO DO TEMPO

Analisar os artistas mais populares pode ser interessante para entender tendências de usuários e auxiliar na preparação de campanhas de divulgação de empresas. Nesta seção, lidamos com a tarefa de encontrar os cinco artistas mais populares, ranqueados pelo número de playlists em que estes aparecem. Além disso, analisamos a popularidade de cada um dos cinco artistas ao longo dos anos, de 2011 até 2017. A Tabela 4 demonstra a quantidade de vezes que cada artista aparece em uma playlist.

Nome do artista	Número de playlists
Drake	32259
Rihanna	23963
Kanye West	22464
The Weeknd	20046
Kendrick Lamar	19159

Tabela 4: Número de playlists por artista

Para realizar essa tarefa, foram seguidas as seguintes etapas:

1. **Artistas mais populares:** Foi criado um DataFrame com o nome de artistas e o número de playlists em que aparecem. A tabela foi ordenada pelo número de playlists de forma decrescente e limitada a cinco artistas.
2. **Faixas listadas por ano:** Criação de DataFrame com todas as faixas listadas por ano, utilizando a função *year* do *pyspark* para converter a data da última modificação para seu ano correspondente.
3. **Artistas mais populares quantizados por ano:** A partir do DataFrame do item 2, é criado um novo DataFrame com as colunas “Nome do artista”, “Ano de modificação”, “Número de playlists”. Esses dados são filtrados apenas para os 5 artistas encontrados no item 1.




Figura 1: Número de playlists contendo cada artistas ao longo dos anos

4. COMPORTAMENTO DE PLAYLISTS

Playlists são coleções de músicas organizadas de acordo com as preferências dos usuários, podendo variar por gênero musical, artista ou outros critérios subjetivos. Nesta seção, analisamos as características predominantes nas playlists: elas são dominadas por faixas de um único artista ou são mais diversificadas?

Para responder a essa pergunta, calculamos a prevalência do artista mais frequente em cada playlist, definida como a razão entre o número de faixas do artista mais recorrente e o total de faixas da playlist.

O processo de análise seguiu as etapas descritas abaixo:

1. **Criação de um DataFrame:** Foi gerado um DataFrame contendo o número de faixas de cada artista em cada playlist.
2. **Adição de Ranqueamento:** Para cada playlist, os artistas foram ordenados com base no número de faixas, sendo atribuído o rank 1 ao artista mais frequente.
3. **Filtragem por Artistas Predominantes:** Apenas os artistas com rank 1 (os mais frequentes em cada playlist) foram mantidos, juntamente com suas respectivas prevalências.
4. **Cálculo da Prevalência Cumulativa:** A prevalência foi ordenada e uma Função de Distribuição Cumulativa (CDF) foi calculada para representar a distribuição da prevalência em todas as playlists.
5. **Normalizar Prevalência Cumulativa:** A prevalência cumulativa é normalizada, para se obter a probabilidade de prevalência cumulativa.

Com base nesses dados, foi criado o gráfico da CDF da prevalência do artista mais frequente, ilustrando como a distribuição se comporta em diferentes níveis de prevalência. Esse gráfico é representado na Figura 2, em que podemos notar um crescimento acentuado da probabilidade cumulativa entre as prevalências de 0,1 e 0,3. Esse crescimento indica que playlists mais ecléticas (com baixa prevalência de um único artista) são mais comuns, enquanto playlists dominadas por um único artista (com alta prevalência) são menos frequentes. Nesse sentido, muitas playlists possuem artistas cuja prevalência é inferior a 50%, o que reflete maior diversidade nessas playlists, enquanto playlists monotemáticas representam uma minoria.




Figura 2: Gráfico da CDF de Prevalência de Artistas em Playlists